Como resolver a prova

Um roteiro direto, do enunciado ao código e à interpretação. Exemplos presumidos para estudar; não são questões confirmadas da prova.

Você não precisa lembrar tudo de uma vez. Primeiro descubra o que a questão pede, depois escolha a ferramenta e explique o resultado.

O roteiro de cinco passos

1. Marque o verbo. Calcular, comparar, contar, relacionar, prever ou proteger?

2. Identifique as colunas. Qual é numérica? Qual separa grupos? Qual é o alvo da previsão?

3. Inspecione a base. Confira nomes, tipos e valores ausentes antes de escrever a solução.

4. Execute a receita. Use apenas o que responde ao enunciado. Não faça toda a análise se ele pede somente uma média.

5. Escreva a conclusão. Número + unidade + significado. Evite entregar apenas a saída do código.

```
df.head()
df.info()
print(df.columns)
print(df.isna().sum())
df.describe()
```

Ordem sugerida de revisão

Pandas e estatística descritiva → quartis e outliers → gráficos → teste A/B → correlação → regressão → R^2 e RMSE → governança e segurança.

LEMBRE: Esta prioridade retoma a revisão da conversa. É uma hipótese de estudo, não uma garantia sobre a prova.

O que a pergunta quer?

Encontre a palavra-chave e vá direto à receita correspondente.

Se o enunciado pedir…	Use…
Média / valor central / mais frequente	.mean() / .median() / .mode()
Dispersão / variabilidade	.std() ou .var()
Média por região ou grupo	groupby + mean
Valor extremo / anomalia	Quartis + IQR; boxplot
Quantidade por categoria	value_counts ou countplot
Comparação visual de médias	barplot
Relação entre duas variáveis numéricas	scatterplot + correlação
Diferença entre médias de grupos independentes	Teste t; confira hipóteses e p-valor
Previsão de uma variável numérica	Regressão, conforme o modelo pedido
Qualidade da regressão	R^2 e RMSE
Dados pessoais desnecessários	Minimização e remoção das colunas

Como escrever uma resposta completa

Modelo: “Usei [método] para analisar [variável/grupos]. Obtive [resultado]. Isso indica [interpretação], considerando [limitação relevante].”

Exemplo: “O gasto médio foi de R$ 520. Como há valores extremos, também analisei a mediana para representar melhor o centro da distribuição.”

Média, mediana e dispersão

Receita: selecione a coluna → aplique a medida → escreva o significado.

```
media = df['Gasto'].mean()
mediana = df['Gasto'].median()
modas = df['Regiao'].mode()
desvio = df['Gasto'].std()
variancia = df['Gasto'].var()
por_regiao = df.groupby('Regiao')['Gasto'].mean()
```

Medida	Como interpretar
Média	Soma dos valores dividida pela quantidade. Sensível a extremos.
Mediana	Valor central dos dados ordenados. Mais resistente a extremos.
Moda	Valor(es) mais frequente(s). Pode haver empate.
Desvio padrão	Dispersão na mesma unidade da variável.
Variância	Dispersão em unidades ao quadrado.

Questão presumida • qual representa melhor?

Gastos: 100, 110, 120, 130 e 5.000. Calcule a média e a mediana. Qual descreve melhor um gasto central nesta amostra?

1. Some: 5.460. 2. Divida por 5: média = 1.092. 3. Pegue o centro da lista ordenada: mediana = 120.

Resposta: “A mediana de R$ 120 representa melhor o centro desta amostra, pois o gasto de R$ 5.000 eleva bastante a média.”

LEMBRE: No Pandas, std() e var() usam por padrão a fórmula amostral (ddof=1). Para a população completa, se solicitado, use ddof=0. mode()[0] retorna só a primeira moda.

Encontre os valores extremos

Primeiro sinalize. Um outlier não é automaticamente um erro nem deve ser excluído sem justificativa.

```
q1 = df['Gasto'].quantile(0.25)
q3 = df['Gasto'].quantile(0.75)
iqr = q3 - q1
li = q1 - 1.5 * iqr
ls = q3 + 1.5 * iqr

outliers = df[(df['Gasto'] < li) | (df['Gasto'] > ls)]

# Se a exclusao for pedida e justificada:
df_limpo = df[
    (df['Gasto'] >= li) & (df['Gasto'] <= ls)
].copy()
```

Questão presumida • calcule as cercas

Se Q1 = 100 e Q3 = 200, o valor 400 é um outlier pela regra de 1,5 × IQR?

1. IQR = 200 − 100 = 100.
2. Limite inferior = 100 − 150 = −50.
3. Limite superior = 200 + 150 = 350.
4. Como 400 > 350, ele é sinalizado como outlier.

Quartil manual: atenção ao método

Ordenando 45, 12, 60, 20, 30, 15, 80: 12, 15, 20, 30, 45, 60, 80. A mediana é 30. Pela mediana das metades, excluindo o centro: Q1 = 15 e Q3 = 60.

LEMBRE: O Pandas usa interpolação linear por padrão: nessa lista, Q1 = 17,5 e Q3 = 52,5. Métodos distintos podem produzir quartis distintos. Use o critério pedido pelo professor.

Escolha o gráfico certo

O gráfico deve responder à pergunta. Não escolha apenas pela aparência.

```
import seaborn as sns
import matplotlib.pyplot as plt
```

Objetivo	Receita
Contar registros por categoria	sns.countplot(data=df, x='Regiao')
Comparar médias	sns.barplot(data=df, x='Regiao', y='Gasto')
Ver distribuição e extremos	sns.boxplot(data=df, y='Gasto')
Ver relação entre números	sns.scatterplot(data=df, x='Tempo', y='Gasto')
Ver evolução no tempo	sns.lineplot(data=df, x='Data', y='Faturamento')

Finalize cada gráfico com plt.show(). Para criar outro separado, use plt.figure() antes da nova chamada.

Questão presumida • região mais frequente

“Qual região tem mais registros? Mostre em um gráfico.”

```
contagens = df['Regiao'].value_counts()
print(contagens)
sns.countplot(data=df, x='Regiao', order=contagens.index)
plt.show()
```

Resposta: “A região com a maior contagem é a mais frequente na base.” Só escreva o nome depois de observar a saída.

LEMBRE: barplot calcula a média por padrão. Para faturamento total por região, agregue com sum(). Em séries temporais, confira as datas e o que deve ser agregado.

Compare grupos com critério

Para comparar médias de dois grupos independentes. Se forem as mesmas pessoas antes e depois, o desenho exige outra abordagem.

H0: as médias populacionais são iguais.
H1: as médias populacionais são diferentes.
α: nível de significância definido antes do teste, por exemplo, 0,05.

```
from scipy import stats

A = df.loc[df['Versao'] == 'A', 'Ticket'].dropna()
B = df.loc[df['Versao'] == 'B', 'Ticket'].dropna()

# Welch: nao pressupoe variancias iguais
t, p = stats.ttest_ind(A, B, equal_var=False)
print('Medias:', A.mean(), B.mean())
print('p-valor:', p)

if p < 0.05:
    print('Rejeita H0: evidencia de diferenca nas medias.')
else:
    print('Nao rejeita H0: evidencia insuficiente.')
```

A receita da conversa usava ttest_ind(A, B), que assume variâncias iguais. Aqui, equal_var=False usa Welch. Siga o teste solicitado e confira independência, tamanho amostral e valores extremos.

Questão presumida • B é superior?

Média A = R$ 120; média B = R$ 135; p = 0,31; α = 0,05.

1. Compare 0,31 com 0,05.
2. Como p > α, não rejeite H0.
3. Responda: “B teve média amostral maior, mas não há evidência estatística suficiente de diferença entre as médias.”

LEMBRE: p-valor não é a probabilidade de H0 ser verdadeira. Não rejeitar H0 não prova igualdade. Significância também não mede o tamanho ou a importância prática da diferença.

Relação não é causa

Leia o sinal, observe a intensidade e confira o gráfico de dispersão.

```
r = df['Tempo'].corr(df['Gasto'], method='pearson')
r_s = df['Tempo'].corr(df['Gasto'], method='spearman')
print(r, r_s)

sns.scatterplot(data=df, x='Tempo', y='Gasto')
plt.show()
```

Resultado	Interpretação
r > 0	À medida que X cresce, Y tende a crescer.
r < 0	À medida que X cresce, Y tende a diminuir.
r próximo de zero	Pouca associação linear para Pearson; pode existir relação não linear.
|r| próximo de 1	Associação forte segundo a medida escolhida.

Pearson ou Spearman?

Pearson: mede associação linear entre variáveis numéricas.
Spearman: trabalha com postos; útil para dados ordinais e relações monotônicas, que mantêm a tendência crescente ou decrescente sem precisar formar uma reta.

Duas questões presumidas

“Pearson = −0,82. Interprete.”
Há uma forte associação linear negativa nesta amostra: quando uma variável aumenta, a outra tende a diminuir. Os limites de “fraca/moderada/forte” dependem do contexto.

“Sorvetes e ataques de tubarão aumentam juntos. Há causa?”
A correlação não prova causalidade. Temperatura ou estação do ano podem estar associadas aos dois fenômenos.

LEMBRE: Outliers podem distorcer Pearson. Uma curva em U pode ter correlação próxima de zero mesmo com uma relação clara. Nem toda curva é monotônica.

Da relação à previsão

Se a tarefa pede prever um número a partir de outro, identifique a entrada X e o alvo y.

```
from sklearn.linear_model import LinearRegression

base = df[['Tempo', 'Gasto']].dropna()
X = base[['Tempo']]  # tabela 2D
y = base['Gasto']    # coluna 1D

modelo = LinearRegression()
modelo.fit(X, y)
pred = modelo.predict(X)

print('Coeficiente:', modelo.coef_[0])
print('Intercepto:', modelo.intercept_)

novo = pd.DataFrame({'Tempo': [45]})
previsao = modelo.predict(novo)[0]
print(f'Previsao: R$ {previsao:.2f}')
```

O código pressupõe import pandas as pd e um DataFrame df. Os nomes das colunas de novo devem coincidir com os usados no treino.

Questão presumida • faça a conta

Modelo: Gasto previsto = 25 × Tempo + 150. Quanto prevê para 20 minutos?

1. Substitua Tempo por 20.
2. Calcule 25 × 20 = 500.
3. Some 150: previsão = R$ 650.

Interprete os parâmetros

Coeficiente 25: a cada minuto adicional, o modelo prevê aumento de R$ 25 no gasto médio. Intercepto 150: previsão do modelo para tempo igual a zero. Pode não ter interpretação prática se zero estiver fora dos dados observados.

LEMBRE: X usa dois colchetes: df[["Tempo"]]. Prever muito além da faixa observada é extrapolar e pode produzir resultados pouco confiáveis.

R², RMSE e faixa de previsão

Calcule a métrica e traduza o resultado para o contexto da pergunta.

```
from sklearn.metrics import r2_score, mean_squared_error

r2 = r2_score(y, pred)
rmse = mean_squared_error(y, pred) ** 0.5
print(f'R2: {r2:.3f}')
print(f'RMSE: R$ {rmse:.2f}')

piso = previsao - rmse
teto = previsao + rmse
```

Questão presumida • explique as métricas

R² = 0,72: o modelo explica aproximadamente 72% da variabilidade do alvo no conjunto avaliado. Não significa “72% de precisão”. R² pode ser negativo quando o modelo é pior que prever a média como referência.

RMSE = 100: a raiz da média dos erros ao quadrado é R$ 100, na mesma unidade do gasto. Resume a magnitude dos erros e penaliza mais os erros grandes.

Previsão = 1.200; RMSE = 100: piso = R$ 1.100 e teto = R$ 1.300. Essa é a faixa operacional simples do exercício, não um intervalo de confiança ou previsão formal.

Treino não é teste

As métricas obtidas com predict(X) sobre os mesmos dados do treino descrevem o ajuste. Para avaliar generalização, separe os dados antes de treinar:

```
from sklearn.model_selection import train_test_split

X_tr, X_te, y_tr, y_te = train_test_split(
    X, y, test_size=0.2, random_state=42
)
modelo.fit(X_tr, y_tr)
pred_te = modelo.predict(X_te)
print(r2_score(y_te, pred_te))
print(mean_squared_error(y_te, pred_te) ** 0.5)
```

Proteja os dados e destrave

Resumo conceitual para o exercício e correções rápidas de código.

Questão presumida • dados desnecessários

“A base contém Nome, Email, CPF, Tempo e Gasto. Você precisa prever Gasto usando Tempo. Quais colunas pessoais são desnecessárias para essa análise?”

```
df_seguro = df.drop(columns=['Nome', 'Email', 'CPF'])
```

Resposta: “Removi os identificadores que não são necessários para a finalidade da análise, aplicando minimização de dados.” Remover essas colunas não garante, por si só, anonimização completa da base.

Tríade de segurança (CIA)	O que lembrar
Confidencialidade	Acesso apenas a quem está autorizado.
Integridade	Proteção contra alterações indevidas.
Disponibilidade	Acesso aos dados e serviços quando necessário.

Se o código falhar

Erro ou sintoma	Primeira correção
NameError: pd não definido	Execute import pandas as pd.
KeyError em uma coluna	Confira print(df.columns).
Expected 2D array	Use X = df[["Tempo"]].
Condição do Pandas ambígua	Use & ou | e parênteses em cada condição.
Modelo não aceita NaN	Inspecione ausentes; trate-os de forma justificada.
Gráfico não aparece	Finalize com plt.show().

Resolva uma questão inteira

Enunciado presumido: analise uma base com Email, Regiao, Versao, Tempo e Gasto. Compare versões e estime gasto para 45 minutos.

Antes de começar: carregue a base, confira as colunas e execute os imports das receitas. Use os nomes reais do arquivo.

```
import pandas as pd
from scipy import stats
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_squared_error

df = pd.read_csv('dados.csv')
print(df.head())
print(df.isna().sum())
df = df.drop(columns=['Email'])

# 1. Resumo e frequencias
print(df['Regiao'].mode())
print(df['Gasto'].describe())

# 2. Sinalizar extremos sem excluir automaticamente
q1, q3 = df['Gasto'].quantile([0.25, 0.75])
iqr = q3 - q1
mascara = (df['Gasto'] < q1 - 1.5 * iqr) | (
    df['Gasto'] > q3 + 1.5 * iqr
)
print(df.loc[mascara, ['Tempo', 'Gasto']])

# 3. Comparar tempo entre versoes independentes
A = df.loc[df['Versao'] == 'A', 'Tempo'].dropna()
B = df.loc[df['Versao'] == 'B', 'Tempo'].dropna()
t, p = stats.ttest_ind(A, B, equal_var=False)
print('Medias:', A.mean(), B.mean(), 'p:', p)

# 4. Medir associacao
print(df['Tempo'].corr(df['Gasto']))
```

Conclusão parcial: informe a região mais frequente, interprete o resumo, sinalize extremos e compare p com α. Não assuma que B vence só porque tem média maior.

Conclua sem dar um salto

Continue o exercício anterior. O modelo abaixo usa os casos completos e mantém os outliers; altere isso apenas com justificativa.

```
# 5. Ajustar regressao
base = df[['Tempo', 'Gasto']].dropna()
X = base[['Tempo']]
y = base['Gasto']
modelo = LinearRegression().fit(X, y)
pred = modelo.predict(X)

# 6. Avaliar o ajuste na propria base
r2 = r2_score(y, pred)
rmse = mean_squared_error(y, pred) ** 0.5

# 7. Prever com os mesmos nomes de colunas
novo = pd.DataFrame({'Tempo': [45]})
previsao = modelo.predict(novo)[0]
print(f'R2 do ajuste: {r2:.3f}')
print(f'RMSE do ajuste: R$ {rmse:.2f}')
print(f'Previsao: R$ {previsao:.2f}')
print(f'Faixa simples: {previsao-rmse:.2f} '
      f'a {previsao+rmse:.2f}')
```

Como entregar a interpretação

“A análise encontrou [resultado descritivo]. O teste A/B apresentou p = [valor], portanto [decisão sobre H0]. A correlação foi [valor e direção]. O modelo estimou R$ [valor] para 45 minutos, com R^2 = [valor] e RMSE = R$ [valor] no conjunto de ajuste.”

Acrescente: “Essas métricas foram calculadas na base de treino. A faixa de ± RMSE é apenas uma referência operacional. É preciso verificar se 45 minutos está dentro da faixa observada.”

Antes de entregar

1. Respondi exatamente ao verbo do enunciado?
2. Usei os nomes corretos e tratei ausentes?
3. Expliquei os resultados com unidade?
4. Justifiquei eventuais exclusões?
5. Evitei confundir associação com causa?
6. Diferenciei ajuste de desempenho em dados novos?

Se travar: escreva o método, a fórmula e a interpretação esperada. Isso demonstra seu raciocínio mesmo que falte parte da sintaxe.

Contar, somar e achar o centro

Cobertura ampliada dos cálculos do guia enviado. As questões abaixo são exemplos criados para treino.

Notação: n = quantidade de observações; Σ = somar; $\bar{x}$ = média; x_i = cada valor; √ = raiz quadrada. Faça as contas por etapas e arredonde só no final.

1. Frequência e porcentagem

Frequência relativa = frequência absoluta / n.
Porcentagem = (parte / total) × 100.
Exemplo: 18 de 60 acessos são do Sul. 18 / 60 = 0,30 → 30%.

2. Média aritmética e média ponderada

$\bar{x} = \Sigma x_i / n$. Para 2, 4, 4 e 6: soma = 16; n = 4; média = 4.
Média ponderada = Σ(valor × peso) / Σpesos.
Notas 6 e 9 com pesos 2 e 3: (6 × 2 + 9 × 3) / 5 = 39 / 5 = 7,8.

Com frequências, use a mesma ideia: valores 10 e 20 com frequências 3 e 2 → (10 × 3 + 20 × 2) / 5 = 14. Não tire a média simples de médias de grupos com tamanhos diferentes.

3. Mediana e moda

Ordene primeiro. Se n é ímpar: posição (n + 1) / 2. Se n é par: média dos valores nas posições n / 2 e n / 2 + 1, contando posições a partir de 1.

2, 4, 4, 6 → mediana = (4 + 4) / 2 = 4; moda = 4.
1, 3, 8 → mediana = 3.
1, 1, 2, 2, 9 → duas modas: 1 e 2.

4. Amplitude e variação percentual

Amplitude = máximo − mínimo. Para 2, 4, 4, 6: 6 − 2 = 4.
Variação (%) = [(novo − antigo) / antigo] × 100.
De 120 para 135: 15 / 120 × 100 = 12,5%. Esse aumento observado não garante significância estatística.

LEMBRE: Média ponderada, porcentagens e amplitude são complementos básicos úteis. Variação percentual exige referência antiga diferente de zero.

Variância e desvio padrão

Questão presumida: calcule as medidas para os valores 2, 4, 4 e 6.

Passo 1: calcule a média: $\bar{x} = 16 / 4 = 4$.
Passo 2: subtraia a média de cada observação.
Passo 3: eleve cada desvio ao quadrado e some.

Valor x_i	Desvio $x_i - \bar{x}$	Desvio²
2	−2	4
4	0	0
4	0	0
6	2	4
Total	0	8

População: divida por N

$\sigma^2 = \Sigma(x_i - \mu)^2 / N$.
Variância populacional = 8 / 4 = 2.
$\sigma = \sqrt{\sigma^2}$ → desvio populacional = $\sqrt{2} \approx 1{,}414$.

Amostra: divida por n − 1

$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$.
Variância amostral = 8 / 3 ≈ 2,667.
$s = \sqrt{s^2}$ → desvio amostral ≈ 1,633.

```
valores = pd.Series([2, 4, 4, 6])
print(valores.var(ddof=0), valores.std(ddof=0))
print(valores.var(ddof=1), valores.std(ddof=1))
```

LEMBRE: Não some desvios e depois eleve ao quadrado: a soma dos desvios é zero. Eleve cada desvio ao quadrado antes de somar. Variância amostral requer n > 1.

Fatie os dados com método

Quartis, IQR e regra de Sturges aparecem no guia de consulta enviado.

Quartis com interpolação linear

Lista ordenada: 10, 20, 30, 40, 50. Use h = (n − 1) × p, com índice inicial zero. Se h tem parte decimal, interpole entre os dois valores vizinhos.

Q1: p = 0,25 → h = 4 × 0,25 = 1 → valor no índice 1 = 20.
Q2: h = 2 → 30.
Q3: h = 3 → 40.

Para 10, 20, 30, 40, Q1: h = 3 × 0,25 = 0,75. Interpole: 10 + 0,75 × (20 − 10) = 17,5.

Cercas e decisão

Com Q1 = 20 e Q3 = 40:
IQR = Q3 − Q1 = 20.
LI = Q1 − 1,5 × IQR = −10.
LS = Q3 + 1,5 × IQR = 70.
80 fica fora; 70 está no limite e não é outlier por essa regra.

Sturges: quantas classes no histograma?

k = 1 + 3,322 × $\log_{10}(n)$.
Para n = 1.000: $\log_{10}(1.000) = 3$.
k = 1 + 3,322 × 3 = 10,966 → aproximadamente 11 classes.

Siga a convenção de arredondamento do enunciado. No guia enviado, o arredondamento é para o inteiro mais próximo. Sturges é uma heurística, não um número universalmente ideal.

Largura de classe, se solicitada

Largura ≈ (máximo − mínimo) / k.
Mínimo 0, máximo 110, k = 11 → largura = 10.

```
import numpy as np
k = round(1 + 3.322 * np.log10(len(df)))
sns.histplot(data=df, x='Gasto', bins=k)
plt.show()
```

Calcule o sinal sobre o ruído

Fórmulas de apoio ao teste A/B. O programa calcula o p-valor a partir da distribuição t.

Welch: grupos independentes

EP = √(s²A / nA + s²B / nB)
t = (média A − média B) / EP
EP é o erro padrão da diferença; s²A e s²B são variâncias amostrais.

Questão: A: média 100, desvio 10, n = 25. B: média 106, desvio 10, n = 25. Existe diferença, usando teste bilateral e α = 0,05?

1. Variâncias: $10^2 = 100$.
2. EP = √(100/25 + 100/25) = √8 ≈ 2,828.
3. t = (100 − 106) / 2,828 ≈ −2,121.
4. Neste exemplo, graus de liberdade = 48 e p ≈ 0,039.
5. p < 0,05: rejeite H0. Há evidência de diferença nas médias.

```
from scipy import stats
t, p = stats.ttest_ind_from_stats(
    mean1=100, std1=10, nobs1=25,
    mean2=106, std2=10, nobs2=25,
    equal_var=False
)
print(t, p)
```

Se pedirem graus de liberdade de Welch

Defina a = s²A/nA e b = s²B/nB.
gl ≈ (a + b)² / [a²/(nA − 1) + b²/(nB − 1)].
Aqui, a = b = 4: gl = 64 / (16/24 + 16/24) = 48.

Student com variâncias iguais

s²p = [(nA − 1)s²A + (nB − 1)s²B] / (nA + nB − 2)
t = (média A − média B) / √[s²p × (1/nA + 1/nB)]
gl = nA + nB − 2. Use apenas quando essa suposição e o desenho forem adequados ou solicitados.

LEMBRE: No teste bilateral, p = 2 × P(T ≥ |t|). Não é possível concluir só pelo sinal de t. Se trocar a ordem dos grupos, o sinal muda, mas o p bilateral não.

Calcule uma relação à mão

Exemplo completo: X = [1, 2, 3] e Y = [2, 4, 5].

1. Médias: $\bar{x} = 2$; $\bar{y} = 11/3 \approx 3{,}667$.
2. Calcule os desvios e seus produtos, mantendo as frações quando possível.

x	y	$x - \bar{x}$	$y - \bar{y}$	Produto
1	2	−1	−5/3	5/3
2	4	0	1/3	0
3	5	1	4/3	4/3

$Sxx = \Sigma(x - \bar{x})^2 = 2$.
$Syy = \Sigma(y - \bar{y})^2 = 25/9 + 1/9 + 16/9 = 14/3$.
$Sxy = \Sigma[(x - \bar{x})(y - \bar{y})] = 3$.

Covariância amostral

$Cov(X,Y) = Sxy / (n - 1) \rightarrow 3 / 2 = 1{,}5$.
Se a questão pedir covariância populacional, divida por n: 3 / 3 = 1.

Correlação de Pearson

$r = Sxy / \sqrt{(Sxx \times Syy)}$
$r = 3 / \sqrt{(2 \times 14/3)} \approx 0{,}982$.
Equivalente: $r = Cov(X,Y) / (sx \times sy)$, usando a mesma convenção amostral ou populacional em todas as medidas.

Resposta: “Há associação linear positiva forte nesses três pares. Isso não prova causalidade nem garante que o padrão se repita em outras amostras.”

```
x = pd.Series([1, 2, 3])
y = pd.Series([2, 4, 5])
print(x.cov(y))
print(x.corr(y))
```

LEMBRE: Se uma das variáveis for constante, seu desvio é zero e a correlação é indefinida. Não interprete NaN como correlação zero.

Postos e reta de previsão

Use os postos para Spearman; use os valores originais para ajustar a regressão.

Spearman sem empates

$r_s = 1 - [6\Sigma d^2 / (n(n^2 - 1))]$, em que d é a diferença entre os postos de X e Y de cada par.

X = [10, 20, 30]; Y = [100, 300, 200].
Postos X = [1, 2, 3]; postos Y = [1, 3, 2].
Diferenças d = [0, −1, 1]; soma $d^2 = 2$.
$r_s = 1 - 12/(3 \times 8) = 0{,}5$.

Com empates, atribua postos médios e calcule Pearson sobre os postos; use a biblioteca. A fórmula curta acima não deve ser aplicada diretamente sem corrigir empates.

Coeficientes da regressão linear simples

$\hat{y} = b_0 + b_1 x$
$b_1 = Sxy / Sxx$
$b_0 = \bar{y} - b_1 \bar{x}$
Aqui, Sxy e Sxx são as somas de produtos e quadrados da página anterior.

Com X = [1, 2, 3] e Y = [2, 4, 5]:
1. $b_1 = 3/2 = 1{,}5$.
2. $b_0 = 11/3 - 1{,}5 \times 2 = 2/3 \approx 0{,}667$.
3. Reta: $\hat{y} = 0{,}667 + 1{,}5x$.
4. Para x = 4: $\hat{y} = 2/3 + 6 \approx 6{,}667$.

O valor x = 4 está fora do intervalo de treino [1, 3]: é extrapolação. A conta é válida para a reta ajustada, mas a confiabilidade da previsão precisa ser discutida.

Resíduo

$e_i = y_i - \hat{y}_i$. Se o valor real é 4 e a previsão é 3,667, o resíduo é +0,333: o modelo subestimou. Se o resíduo for negativo, o modelo superestimou.

LEMBRE: OLS escolhe os coeficientes para minimizar Σe^2. O efeito descrito pelo coeficiente é uma associação prevista pelo modelo, não uma conclusão causal automática.

MAE, MSE, RMSE e R²

Questão presumida: valores reais [3, 5, 7]; previsões [2, 5, 8]. Avalie o modelo.

Real y	Previsto ŷ	e = y − ŷ	|e|	e²
3	2	1	1	1
5	5	0	0	0
7	8	−1	1	1
Total			2	2

1. MAE: média dos erros absolutos

MAE = Σ|y − ŷ| / n → 2/3 ≈ 0,667.
Mesma unidade do alvo. Não deixa erros positivos e negativos se anularem.

2. MSE e RMSE

MSE = Σ(y − ŷ)² / n → 2/3 ≈ 0,667.
RMSE = √MSE → √(2/3) ≈ 0,816.
MSE está na unidade ao quadrado; RMSE volta à unidade original.

3. R²: compare com a média do alvo

R² = 1 − SSE/SST.
SSE = Σ(y − ŷ)² = 2.
Média real ȳ = (3 + 5 + 7)/3 = 5.
SST = Σ(y − ȳ)² = (3 − 5)² + 0² + (7 − 5)² = 8.
R² = 1 − 2/8 = 0,75: 75% da variabilidade do alvo é explicada no conjunto avaliado.

```
from sklearn.metrics import mean_absolute_error
y_real = [3, 5, 7]
y_pred = [2, 5, 8]
print(mean_absolute_error(y_real, y_pred))
print(mean_squared_error(y_real, y_pred) ** 0.5)
print(r2_score(y_real, y_pred))
```

LEMBRE: Para regressão linear simples por mínimos quadrados com intercepto, R² = r² no treino. Não aplique essa identidade a qualquer modelo ou conjunto de teste. Se SST = 0, a fórmula usual de R² tem denominador zero.

Se a prova for além do básico

Conteúdo de apoio à inferência. Menor prioridade que as fórmulas anteriores; não confirmado como cobrança pelo material consultado.

Erro padrão da média

EP = s / √n. Se s = 20 e n = 100, EP = 20/10 = 2.
O desvio descreve a dispersão dos indivíduos; o erro padrão descreve a incerteza da média estimada, sob as hipóteses de amostragem.

Intervalo de confiança para uma média

IC = $\bar{x}$ ± valor crítico × EP.
Com desvio populacional desconhecido, a receita clássica usa o crítico t com n − 1 graus de liberdade, sob condições apropriadas.

Exemplo aproximado com amostra grande: $\bar{x}$ = 100; s = 20; n = 100. Usando crítico normal 1,96: margem = 1,96 × 2 = 3,92; IC de 95% ≈ [96,08; 103,92]. Com crítico t de 99 gl, o intervalo fica ligeiramente maior.

Interpretação: em repetições do procedimento de amostragem, cerca de 95% dos intervalos construídos dessa forma conteriam a média populacional. Não é o mesmo que prever o gasto de um indivíduo.

Escore z

z = (x − μ)/σ. Se x = 130, μ = 100 e σ = 15: z = 30/15 = 2. O valor está dois desvios acima da média. Converter isso em probabilidade requer uma distribuição assumida, como a normal.

Coeficiente de variação

CV = (s / $\bar{x}$) × 100%. Se média = 100 e desvio = 20, CV = 20%. Útil para dispersão relativa em escalas com zero significativo e médias positivas; fica inadequado ou instável perto de média zero.

As quatro armadilhas de cálculo

1. Trocar n por n − 1 sem observar se é amostra ou população.
2. Arredondar médias e resíduos cedo demais.
3. Usar porcentagem como número inteiro: 5% = 0,05.
4. Confundir ± RMSE com um intervalo de confiança de 95%.

Fórmulas para consulta rápida

Priorize as linhas ligadas ao enunciado. Não há como garantir todas as questões da prova.

Cálculo	Fórmula
Média	$\bar{x} = \Sigma x / n$
Média ponderada	$\Sigma(\text{valor} \times \text{peso}) / \Sigma\text{pesos}$
Variância amostral	$s^2 = \Sigma(x - \bar{x})^2 / (n - 1)$
Variância populacional	$\sigma^2 = \Sigma(x - \mu)^2 / N$
Desvio padrão	Raiz quadrada da variância
IQR e cercas	IQR = Q3 − Q1; LI/LS = Q1 − 1,5IQR / Q3 + 1,5IQR
Sturges	$k = 1 + 3{,}322 \log_{10}(n)$
Welch	$t = (\text{média A} - \text{média B}) / \sqrt{s^2A/nA + s^2B/nB}$
Covariância amostral	$\Sigma[(x - \bar{x})(y - \bar{y})] / (n - 1)$
Pearson	$r = Sxy / \sqrt{(Sxx \times Syy)}$
Spearman sem empates	$r_s = 1 - 6\Sigma d^2 / [n(n^2 - 1)]$
Regressão simples	$b_1 = Sxy/Sxx$; $b_0 = \bar{y} - b_1\bar{x}$; $\hat{y} = b_0 + b_1x$
Resíduo e MAE	$e = y - \hat{y}$; $MAE = \Sigma\lvert e\rvert/n$
MSE e RMSE	$MSE = \Sigma e^2/n$; $RMSE = \sqrt{MSE}$
R^2	$1 - \Sigma(y - \hat{y})^2 / \Sigma(y - \bar{y})^2$

Base: passo a passo da conversa e GUIA_CONSULTA_PROVA_DATASCIENCE.md enviado. Os exemplos numéricos desta ampliação são didáticos; as explicações foram ajustadas para evitar conclusões estatísticas indevidas.