GUIA DE SOCORRO PARA A PROVA

Ciência de Dados - códigos, conceitos, interpretação e roteiro de resolução

Baseado nos materiais enviados: Estatística Descritiva, Inferência Estatística, Correlação/Causalidade, Regressão Linear, Governança de Dados e LGPD, além dos notebooks de revisão.

Se pedirem...	Pense em...
Resumo da base	head(), info(), describe()
Média / mediana / moda	mean(), median(), mode()
Outliers	quartis, IQR, boxplot
Comparar grupos A/B	ttest_ind + p-valor
Relação entre números	scatterplot + correlação
Prever valor	LinearRegression
Proteção de dados	LGPD, minimização, CIA

1. Bloco de emergência - imports

Se der branco, comece por este bloco. Ele cobre quase todo o conteúdo prático das aulas.

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt

from scipy import stats
from sklearn.linear_model import LinearRegression
from sklearn.metrics import root_mean_squared_error, r2_score
```

Dica: se aparecer NameError, confira primeiro se o import correspondente foi executado.

2. Pandas - o básico que salva

Inspeção rápida da base

```
df.head()
df.info()
df.describe()
print(df.columns)
```

Seleção e filtro

```
df['Gasto']
df[['Tempo', 'Gasto']]

df[df['idade'] > 30]
df[(df['idade'] >= 18) & (df['idade'] <= 30)]
```

Agrupamento

```
df.groupby('versao')['ticket'].mean()
df.groupby('Regiao')['Gasto'].median()
df.groupby('versao')['ticket'].describe()
```

Erro clássico: em Pandas use & para E e | para OU, sempre com cada condição entre parênteses.

3. Estatística descritiva

Média, mediana, moda e desvio padrão

```
media = df['Gasto'].mean()
mediana = df['Gasto'].median()
moda = df['Regiao'].mode()[0]
desvio = df['Gasto'].std()
```

- Média: ponto de equilíbrio, mas sofre bastante com outliers.
- Mediana: valor central da base ordenada; é mais resistente a extremos.
- Moda: valor ou categoria que mais se repete.
- Desvio padrão: mede o quanto os valores estão espalhados em torno da média.

Leitura rápida

- média ≈ mediana → distribuição provavelmente menos distorcida.
- média muito maior que a mediana → desconfie de valores extremos altos.

4. Quartis, IQR e outliers

Quartis dividem a base ordenada em quatro partes: Q1 = 25%, Q2 = 50% (mediana), Q3 = 75%.

```
q1 = df['ticket'].quantile(0.25)
q2 = df['ticket'].quantile(0.50)
q3 = df['ticket'].quantile(0.75)

iqr = q3 - q1

limite_inferior = q1 - 1.5 * iqr
limite_superior = q3 + 1.5 * iqr
```

Filtrar os valores fora da faixa

```
df_limpo = df[
    (df['ticket'] >= limite_inferior) &
    (df['ticket'] <= limite_superior)
]
```

Decore: IQR = Q3 - Q1. Limites: Q1 - 1,5×IQR e Q3 + 1,5×IQR.

5. Gráficos - qual escolher

Situação	Gráfico
Contar categorias	countplot
Comparar média entre categorias	barplot
Distribuição / outliers	boxplot
Distribuição contínua	histplot
Duas variáveis numéricas	scatterplot
Evolução no tempo	lineplot
Correlação entre várias variáveis	heatmap

```
sns.countplot(data=df, x='Regiao')

sns.barplot(data=df, x='Regiao', y='Gasto')

sns.boxplot(data=df, x='versao', y='ticket')

sns.scatterplot(data=df, x='Tempo_Tela', y='Gasto')

sns.lineplot(data=df, x='Data', y='Faturamento')

sns.heatmap(df.corr(numeric_only=True), annot=True)
```

6. Correlação e causalidade

```
r = df['Tempo'].corr(df['Gasto'])
print(r)

matriz = df.corr(numeric_only=True)
print(matriz)
```

- r próximo de +1 → relação linear positiva forte.
- r próximo de -1 → relação linear negativa forte.
- r próximo de 0 → pouca relação linear.

Regra de ouro: correlação NÃO implica causalidade. Pode existir coincidência, variável oculta ou relação indireta.

Pearson x Spearman

```
pearson = df['X'].corr(df['Y'], method='pearson')
spearman = df['X'].corr(df['Y'], method='spearman')
```

• Pearson: melhor para relação linear.

• Spearman: útil para relação monotônica / baseada em ranking, mesmo que não seja perfeitamente linear.

7. Teste A/B e p-valor

Hipóteses mais comuns: H0 = não existe diferença; H1 = existe diferença.

```
grupo_A = df[df['versao'] == 'A']['ticket']
grupo_B = df[df['versao'] == 'B']['ticket']

t, p_valor = stats.ttest_ind(grupo_A, grupo_B)

if p_valor < 0.05:
    print('Rejeita H0: diferença estatisticamente significativa')
else:
    print('Não rejeita H0: sem evidência suficiente de diferença')
```

Decore: p < 0,05 → rejeita H0. p ≥ 0,05 → não rejeita H0.

• Não escreva 'H0 foi provada'. O correto é dizer que não houve evidência suficiente para rejeitá-la.

• Diferença de média sozinha não basta: pode ser apenas variação amostral.

8. Regressão linear simples

A ideia é aprender uma reta que transforma uma entrada X em uma previsão ŷ.

Equação: ŷ = w1·x + w0

• w1 = coeficiente / inclinação / peso.

• w0 = intercepto / viés.

```
X = df[['Tempo_Tela_Min']]
y = df['Gasto_Site_R$']

modelo = LinearRegression()
modelo.fit(X, y)

previsoes = modelo.predict(X)

print(modelo.coef_)
print(modelo.intercept_)
```

Importante: use dois colchetes em X: df[['coluna']]. O sklearn espera X em formato 2D.

9. R², RMSE e previsão

```
r2 = r2_score(y, previsoes)
rmse = root_mean_squared_error(y, previsoes)

print(r2)
print(rmse)
```

• R²: indica quanto da variabilidade de Y é explicada pelo modelo.

• Não diga: 'R² de 0,80 = 80% de precisão'.

• RMSE: erro típico da previsão, aproximadamente na mesma unidade de Y.

Prever um novo caso

```
previsao = modelo.predict([[45]])[0]

piso = previsao - rmse
teto = previsao + rmse

print(f'Previsão: {previsao:.2f}')
print(f'Piso: {piso:.2f}')
print(f'Teto: {teto:.2f}')
```

Essa faixa ±RMSE é uma aproximação operacional usada nos exercícios; não é um intervalo de confiança formal.

10. LGPD, governança e tríade CIA

CIA

• Confidencialidade: apenas pessoas autorizadas acessam os dados.

• Integridade: os dados não devem ser alterados indevidamente.

• Disponibilidade: dados e sistemas precisam estar acessíveis quando necessários.

Princípios trabalhados no material

• Finalidade: coleta/processamento precisam de objetivo claro.

• Adequação: o uso deve ser compatível com a finalidade informada.

• Minimização: coletar e manter apenas o mínimo necessário.

Exemplo de prova

```
# E-mail não é necessário para a análise
df_seguro = df.drop(columns=['Email'])
```

• Dado pessoal: identifica ou pode identificar uma pessoa.

• Dado sensível: exige proteção reforçada por envolver informações de maior risco de discriminação ou impacto.

11. Código-resumo para deixar fresco na cabeça

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

from scipy import stats
from sklearn.linear_model import LinearRegression
from sklearn.metrics import root_mean_squared_error, r2_score

# Estatística
df['x'].mean()
df['x'].median()
df['x'].mode()[0]
df['x'].std()
df['x'].describe()

# Filtro
novo = df[df['x'] < valor]

# GroupBy
df.groupby('grupo')['x'].mean()

# Outliers
q1 = df['x'].quantile(0.25)
q3 = df['x'].quantile(0.75)
iqr = q3 - q1
li = q1 - 1.5 * iqr
ls = q3 + 1.5 * iqr
limpo = df[(df['x'] >= li) & (df['x'] <= ls)]

# Correlação
df['x'].corr(df['y'])
df.corr(numeric_only=True)

# Teste A/B
A = df[df['grupo'] == 'A']['x']
B = df[df['grupo'] == 'B']['x']
t, p = stats.ttest_ind(A, B)

# Regressão
X = df[['x']]
y = df['y']
modelo = LinearRegression()
modelo.fit(X, y)
pred = modelo.predict(X)

r2 = r2_score(y, pred)
rmse = root_mean_squared_error(y, pred)

novo = modelo.predict([[45]])[0]
```

12. O que provavelmente pode aparecer

- Interpretar mean(), median(), std() e describe().
- Encontrar quartis e remover outliers usando IQR.
- Escolher o gráfico adequado para cada tipo de pergunta.
- Comparar dois grupos com Teste A/B e interpretar p-valor.
- Calcular/interpretar correlação e explicar por que correlação não prova causalidade.
- Treinar uma regressão linear simples e fazer uma previsão.
- Interpretar coeficiente, intercepto, R^2 e RMSE.
- Aplicar conceitos de LGPD: finalidade, adequação e minimização.

Ordem de prioridade para estudar: Pandas → estatística descritiva → quartis/IQR → gráficos → Teste A/B → correlação → regressão → LGPD.

13. Erros rápidos e como sair deles

Erro	O que conferir
NameError	Import ou variável não executada.
KeyError: 'coluna'	Use print(df.columns) e confira o nome exato.
Erro no LinearRegression	X deve ser 2D: df[['x']], não df['x'].
Erro com and/or em Pandas	Use & e | com parênteses.
Gráfico não aparece	Chame plt.show().

14. Checklist de 2 minutos antes de começar

- Leia a pergunta e identifique: categoria, número, tempo, grupo ou previsão?
- Confira o nome exato das colunas antes de codar.
- Se for média entre grupos: groupby ou barplot.
- Se for outlier: quartis + IQR + boxplot.
- Se for A/B: separar grupos + ttest_ind + p-valor.
- Se for relação numérica: scatterplot + corr().
- Se for previsão: X 2D + LinearRegression + fit() + predict().
- Ao interpretar, escreva em palavras o que o número significa.

Objetivo deste material: servir como revisão rápida. Use-o de acordo com as regras da sua avaliação.